

Relatório curto - PCA e MDS em vendas de açougue

Dataset: Sales at a Chain of Butcher Shops (Kaggle)

Objetivo. Investigar padrões de venda entre produtos e lojas usando PCA e MDS como técnicas exploratórias de redução/projeção dimensional. Como o arquivo é propositalmente poluído, a limpeza foi considerada parte essencial da análise.

Preparação dos dados

Foram removidos valores ausentes, datas inválidas, textos indevidos em colunas numéricas, valores negativos/zerados e outliers extremos pelo método IQR. A base começou com 4120 registros e ficou com 3049 após a limpeza. Depois, os dados foram agregados por Produto e Loja, gerando 30 registros analíticos.

Etapa	Registros
Originais	4120
Após ausentes/conversões	3282
Após negativos/zerados	3246
Após IQR	3049


Features utilizadas

As features selecionadas foram: numero_vendas, quantidade_total, preco_medio, preco_std, receita_total, ticket_medio e dias_com_venda. Elas resumem volume, receita, preço, variação de preço e frequência de venda.

Resultados do PCA


PC1 explicou 52.83% da variância; PC2 explicou 24.56%; juntos, explicaram 77.39%. Com três componentes, a variância acumulada chegou a 88.75%.

O PC1 foi dominado por quantidade_total, receita_total, numero_vendas e dias_com_venda, representando o desempenho comercial. O PC2 foi mais influenciado por ticket_medio e preco_medio, representando diferenças de preço e valor médio das vendas.



Resultados do MDS

O MDS também preservou bem as proximidades entre registros. A correlação de Spearman entre as distâncias originais e a projeção MDS 2D foi 0.9347; no PCA 2D foi 0.9315. Isso indica que as duas projeções representam bem a estrutura geral dos dados.



Descobertas principais

- Chorizo apareceu como o produto com maior desempenho médio, combinando maior receita total, maior quantidade vendida e maior número de vendas.
- Cerdo ficou com menor receita média agregada e menor volume médio, indicando desempenho comercial mais baixo no conjunto limpo.
- Os pontos mais afastados no PCA representam combinações Produto-Loja com comportamento diferenciado, principalmente por volume, receita, preço médio ou variação de preço.
- PCA e MDS apresentaram padrões parecidos, sugerindo que a estrutura observada não depende apenas de uma única técnica de projeção.
- O PCA é mais adequado para redução de features, enquanto o MDS é mais útil para visualização de similaridade entre registros.

Possíveis outliers na projeção

Produto	Loja	Dist. PCA	Receita total	Ticket médio
Cerdo	La Vaca Feliz	4.15	118089.25	1513.96
Costilla	Super Carnes	4.14	155987.87	1310.82
Chorizo	Cortes Finos MX	4.06	186887.87	1519.41
Res	El Torito	3.41	122188.66	1372.91
Res	Super Carnes	3.38	187183.94	1671.29

Conclusão

A análise mostrou que, após a limpeza do dataset poluído, os métodos PCA e MDS ajudaram a identificar diferenças comerciais entre produtos e lojas. O principal padrão encontrado foi a separação por desempenho de vendas, especialmente volume e receita. A visualização em duas dimensões foi suficiente para uma boa análise exploratória, pois PC1 e PC2 explicaram mais de 77% da variância. O MDS confirmou proximidades semelhantes às do PCA, reforçando a coerência dos resultados.

Fonte do dataset: <https://www.kaggle.com/datasets/frrrmin/sales-at-a-chain-of-butcher-shops>